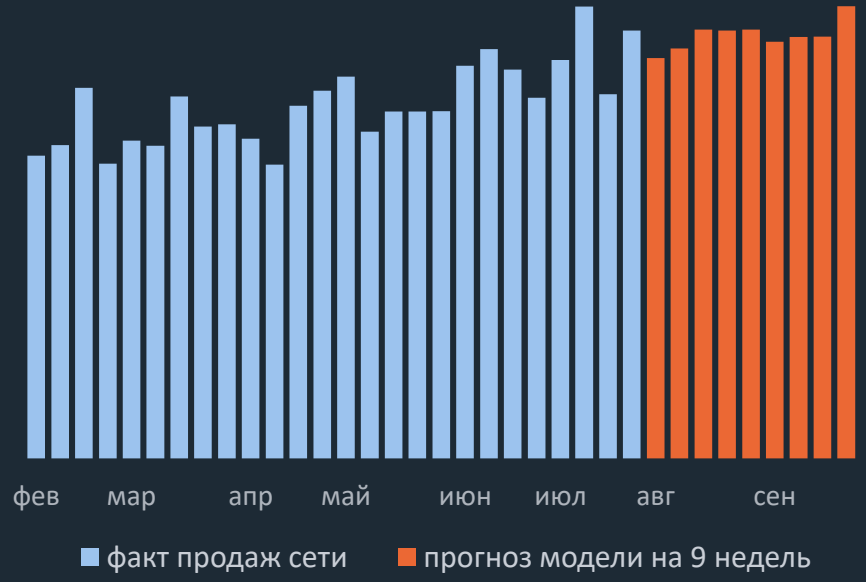
Прогноз продаж по складам и товарам

Команда “Монета”

Светличный Сергей, Калинский Виталий, Дужнов Роман, Мозжухин Тимофей, Калачёв Александр



Продажи всей сети по неделям: факт за февраль–июль 2026 и прогноз модели на август–сентябрь

Зачем это бизнесу

Ошибка в запасах стоит денег в обе стороны



Привезли больше

деньги заморожены в товаре, склад занят, залежавшееся приходится уценять

или



Не привезли

клиент ждёт поставку или уходит к конкуренту — выручка теряется

ЛАГИ: ПОД ЗАКАЗ

25 %

продаж — при нулевом остатке: клиент платит и ждёт

МЁРТВЫЕ ЗОНЫ

86 пар

товар без спроса; у 79 из них он продаётся на других складах

ТОВАР ЛЕЖИТ

529 шт.

точечная заморозка в 46 позициях

ЛОГИСТИКА

192 из 235

ходовых пар без запаса — а товар лежит на складе 6

Задача и данные

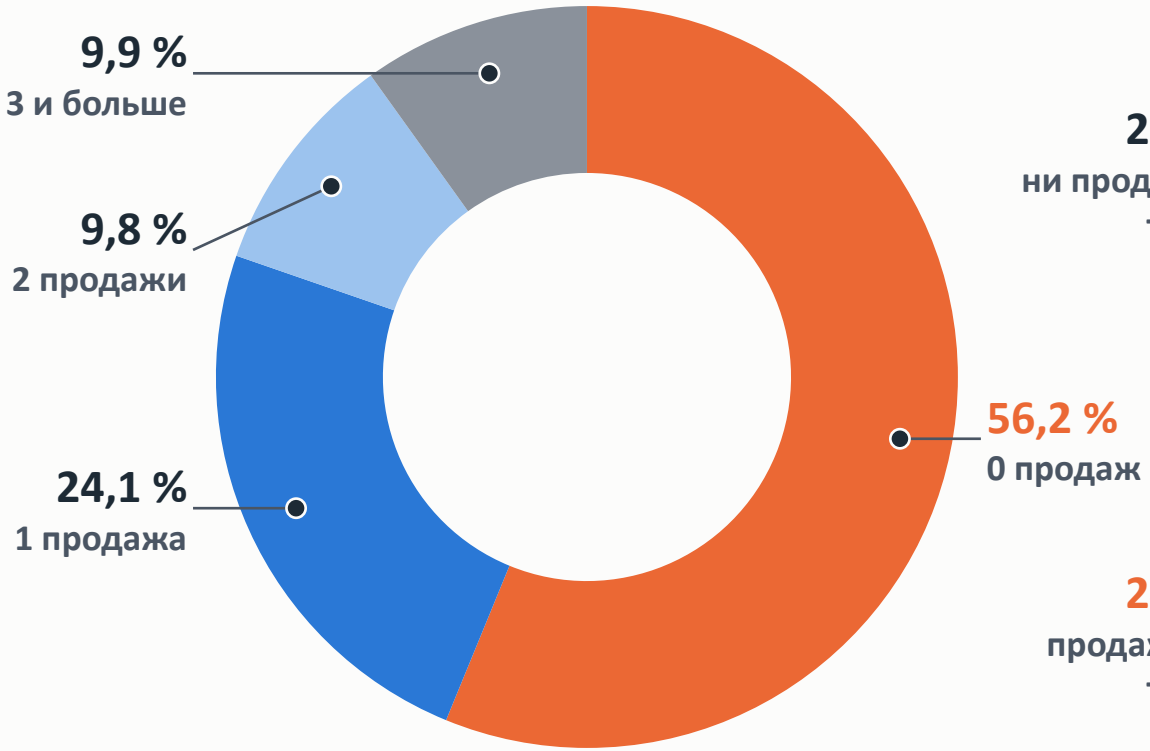
Склады	**11**
Товары	**799**
Пары «склад × товар»	**8 789**
История	**январь 2024 — июль 2026**
Записей	**7,6 млн (продажи 1,49 млн, остатки 6,15 млн)**
Покупатели	**из 209 городов**
Горизонт прогноза	**9 недель: 27.07–27.09.2026**
Значений в прогнозе	**79 101**

Данные чистые

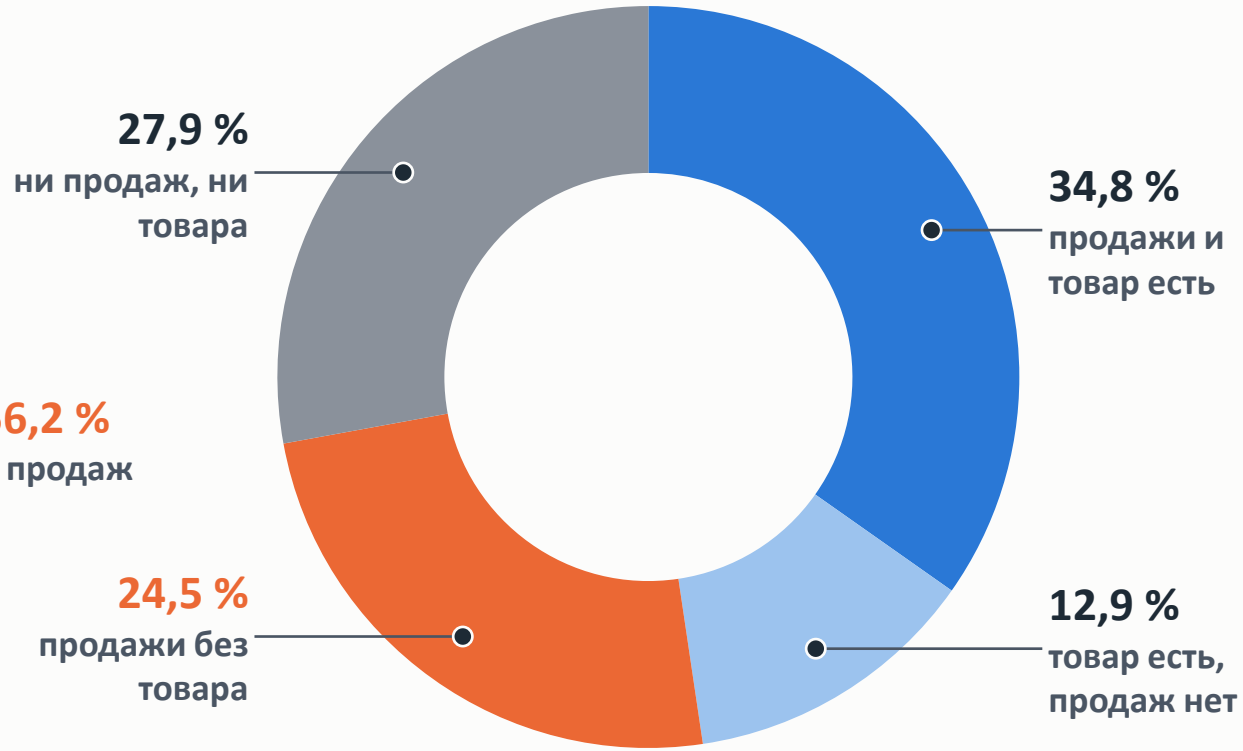
- Пропусков нет
- Отрицательных и дробных продаж нет
- Отрицательный остаток — резерв под заказ, а не ошибка
- Крупные заказы до 200 шт. — настоящие, не вырезали

Особенности спроса

Сколько продаж в неделю у пары



Продажи и наличие товара



Отсюда — двухступенчатая модель



Почему две ступени

Больше половины недель — нули. Одна регрессия усредняет их и выдаёт дробный шум 0,1–0,3 шт. там, где спроса нет. Классификатор решает, будет ли продажа: порог 0,55 на неделях 1–4 и 0,5 на неделях 5–9.

Регрессор

Учится только на неделях с продажами. Таргет — ln(1 + y), чтобы редкие оптовые всплески не раздували обычный прогноз.

Целое число

Складу нельзя отдать план в 1,4 шт. Продажи = 1 + Пуассон(q − 1), выбираем целое с наименьшей ожидаемой ошибкой. Самый большой одиночный шаг улучшения.

Почему CatBoost и почему не нейросеть

Почему CatBoost



Жёсткая регуляризация
симметричные деревья держат шумные данные



Объяснимость
по SHAP-вкладам сервис отвечает, почему прогноз такой



Проверен в индустрии
разработан Яндексом, открытый код, широко используется в продакшене

Почему не нейросеть



Мало данных на пару
около 130 недель, и больше половины — нули



На таблицах бустинги сильнее
это видно и по соревнованиям по прогнозу продаж



Дорого и непрозрачно
нужен GPU, хуже объясняется, дольше учится — значит, меньше экспериментов

Признаки



Как читать

Аблейшн: группу убирали и смотрели, насколько хуже. Шум — меньше 0,1 п. п.

Сильнее всего — категории и спрос по всей сети: это «сигналы сверху».

У классификатора тот же порядок: категории, спрос по сети, календарь, тренды.

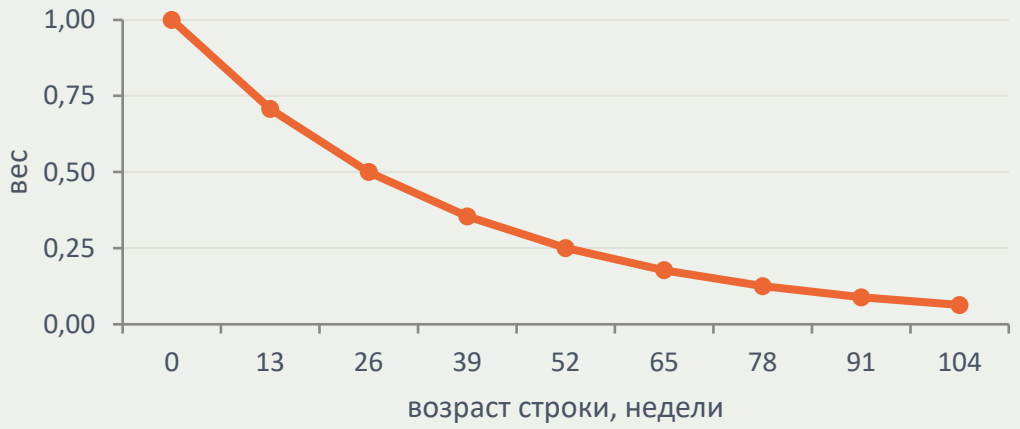
Лаги пары почти не влияют — следует из слабой автокорреляции.

Затухание весов и ансамбль

Затухание весов

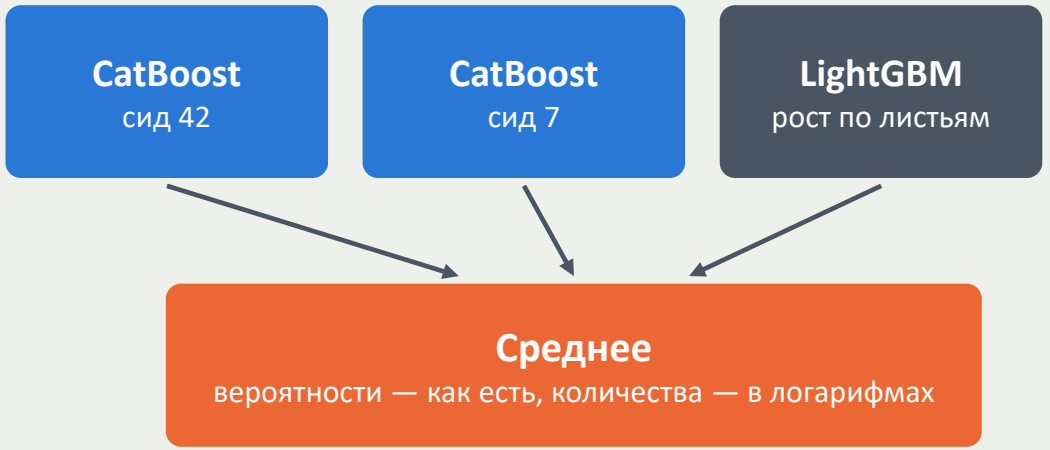
$$w = 0{,}5^{\,t\,/\,26}$$

t — возраст строки в неделях. Свежим неделям модель верит больше, но старые не выбрасывает.



0,5 полгода	**0,25** год	**0,06** два года

Ансамбль



LightGBM в ансамбле улучшил score на всех трёх отсечках.

сезон 2025 **0,809 → 0,808**	сезон 2024 **0,823 → 0,820**	свежие 9 нед. **0,788 → 0,785**

Как обучали: бэктест и лидерборд

1. **Идея**
   одна гипотеза за раз

2. **Бэктест на 3 отсечках по 9 недель**
   сезон 2025 · сезон 2024 · последние 9 недель

3. **Сравнение с базой в том же прогоне**
   GPU даёт шум ±0,0006

4. **Берём или откатываем**
   не хуже на обоих сезонах и почти не хуже на свежих

26 идей проверено · 7 вошли в модель



Как работает сервис

POST /predict CSV продаж + CSV остатков (180+ дней)

↓

forecast_id SHA-256 от версии модели и обоих файлов

→ **Уже считали?** отдаём из кэша без пересчёта — байт в байт (идемпотентность)

↓

Проверка входа (fail-fast) колонки · даты · ≥ 180 дней · продажи ≥ 0 · не пустые

→ **Ошибка во входе** 422 и понятный список того, что не так; ресурсы на расчёт не тратятся

↓

Модель уже в памяти классификатор → регрессор → целое

↓

Сохранение в кэш под своим forecast_id, атомарная запись

↓

Ответ forecast_id + CSV (опц.)

↓

Запросы к прогнозу GET /predict?article=&warehouse= · /predict/all · /explain

FastAPI + uvicorn в Docker

Модель загружается один раз при старте. Прогноз можно забрать по товару, по складу, по паре или целиком; весь прогноз отдаётся файлом или потоком JSON без сборки в памяти.

Надёжность и поддержка

Надёжность

Переживает перезагрузку
прогнозы в кэше, атомарная запись, автоперезапуск

Без интернета, on-prem
модель, библиотеки и документация в образе; работает в контуре заказчика, данные не уходят

Stateless
процессы не держат состояние, общее — только кэш; несколько копий за балансировщиком

Защита по памяти
число одновременных расчётов ограничено, полный расчёт — до ~1 ГБ

Поддержка

OpenAPI-документация офлайн
/docs: файл можно загрузить прямо из браузера; клиенты генерируются из схемы

19 автотестов + smoke
smoke-скрипт проверяет живой сервис

CI на GitHub Actions
тесты в образе → сборка → запуск → проверка ручек; следующий шаг — CD

Полная документация по проекту
README и docs/: данные, модель, сервис, Docker, тесты, ноутбуки, Kaggle; обзор решения — /solution

Риски и как их снизить

Модель не знает будущих акций
скидки в крупнейшей категории рекордные

→ сейчас планировщик правит прогноз по его объяснению; дальше — промо-календарь заказчика в модели

Нет информации о поставках
модель видит остаток, но не то, что уже едет, и не сроки поставки

→ взять у заказчика план и сроки поставок: сравнивать спрос с «остатком + тем, что едет», страховой запас считать под реальный срок

Новые товары
у заказчика их мало: 0,2 % продаж прошлого сезона

→ товар с других складов модель уже видит по спросу сети; совсем новый — прогноз по похожим, на старте вручную

Данные анонимизированы
вместо названий — номера складов и товаров

→ при внедрении — справочник «название → код» и переобучение на реальных данных заказчика

Заключение

Есть модель
она предсказывает продажи каждого товара на каждом складе на 9 недель вперёд: будет ли продажа и сколько штук

Она точнее привычного планирования
ошибка в штуках на 17,6 % меньше, чем «как на прошлой неделе»

Она готова к внедрению
сервис в Docker: работает без интернета, с тестами и полной документацией

Она показывает главное для бизнеса
где ходовым товарам не хватает запаса, где товар лежит не там и где заморожены деньги